

FEATURE ENGINEERING ANALYSIS

IVF 데이터 피처 분석 리포트

총 생성 배아 수·미세주입 난자 수·남성 불임 원인의 상호작용 분석과, 62개 피처 전처리 가이드 및 실행 로드맵

DATASET

train.csv

SAMPLES

250,060

TARGET

임신 성공 여부

POSITIVE RATE

26.16%


CONTENTS

01	총 생성 배아 수 3그룹 특성 분석	Part 01
02	그룹 경계의 선택 — 7 vs 10	Part 02
03	미세주입 피처의 구조적 특수성	Part 03
04	남성요인 × ICSI 상호작용	Part 04
05	미세주입 난자 수의 최적 구간	Part 05
06	파이프라인 단계 매핑	Part 06
07	파생변수 실험 — 원본을 빼도 되는가	Part 07
08	도메인 지식 토대 — IVF 7단계	Part 08
09	피처 확장 가이드 (29~52번)	Part 09
010	데이터 품질 · 논리 제약 검증	Part 10

Part 01

총 생성 배아 수 3그룹 특성 분석

7개 미만, 7~20개, 20개 초과로 나눈 세 집단은 단순히 배아 개수만 다른 것이 아니라, 환자 프로파일·시술 전략·결과까지 모두 다른 별개의 집단으로 드러났다.



그룹별 비교표

환자 프로파일

항목	① 7개 미만	② 7~20개	③ 20개 초과
만 18-34세	34.67%	51.39%	63.21%
만 38세 이상	42.62%	26.01%	16.38%
만 45세 이상	3.29%	1.36%	0.85%
이전 총 시술 횟수 (평균)	1.71회	1.09회	0.95회

불임 원인

항목	① 7개 미만	② 7~20개	③ 20개 초과
----	---------	---------	----------

항목	① 7개 미만	② 7~20개	③ 20개 초과
배란 장애	11.97%	15.44%	31.71%
자궁내막증	7.83%	6.10%	3.84%
남성 요인	37.04%	37.16%	30.01%
난관 질환	14.20%	14.18%	13.03%

시술 전략과 결과

항목	① 7개 미만	② 7~20개	③ 20개 초과
배란 자극 시행	69.49%	95.09%	95.25%
동결 배아 사용	23.68%	0.03%	0%
단일 배아 이식	18.33%	34.05%	26.70%
이식 없음 (freeze-all)	15.64%	11.62%	48.37%
임신 성공률 (전체)	22.07%	35.03%	22.64%
임신 성공률 (이식한 경우)	26.15%	39.62%	43.74%

핵심 관찰

"많을수록 좋다"는 관계는 깨끗한 역U자를 이룬다. 전체 임신 성공률은 ② 35.0% > ③ 22.6% ≈ ① 22.1%. 다만 ③의 낮은 숫자는 **의도적 freeze-all 전략** 때문이며, 실제 이식 건만 비교하면 ③ > ② > ① 순서로 "많을수록 좋다"는 관계가 회복된다.

Part 02

그룹 경계의 선택 — 7 vs 10

"0-9 / 10-19 / 20+"는 직관적으로 깔끔하지만, 데이터가 말해주는 자연적 단절점은 6과 7 사이다. 7-9개 구간의 성질이 결정적 증거다.

세부 구간별 지표 비교

구간	건수	임신 성공률	이식 안 한 비율	배란 자극	만 18-34세
A: 0~6개	169,359	22.07%	15.64%	69.49%	34.67%
B: 7~9개	40,780	34.66%	8.25%	94.23%	47.91%
C: 10~14개	29,556	36.07%	12.31%	96.03%	54.17%

구간	건수	임신 성공률	이식 안 한 비율	배란 자극	만 18-34세
D: 15~19개	7,852	33.56%	24.39%	95.92%	58.06%
E: 20개 정확히	640	28.59%	37.66%	96.09%	63.12%
F: 21개 이상	1,873	22.64%	48.37%	95.25%	63.21%

판정

B(7~9개) 구간은 A(0~6개)가 아니라 C~D(10~19개)와 한 집단이다. 성공률(34.66% vs 36.07%), 배란 자극 (94% vs 96%), 이식 안 한 비율(8% vs 12%) 세 지표 모두 그렇게 말한다. 따라서 0~9 로 묶으면 성질이 다른 두 집단이 섞이며, 데이터의 가장 중요한 경계가 지워진다.

더 권장되는 4분할

임상 문헌과 데이터가 함께 지지하는 구분

그룹	범위	임상적 의미	성공률
저반응 (Poor)	0~6개	난소 반응 저하, 고령 다수	≈22%
정상반응 (Normal)	7~14개	이상적 영역	≈35%
고반응 (High)	15~20개	OHSS 경계, freeze-all 등장	≈33%
과반응 (Hyper)	21개+	PCOS 의심, 전부 동결	≈23%

국제 임상 기준(Bologna · POSEIDON · Sunkara 연구)이 제시하는 경계는 4 , 9 , 15 , 20 이며, 본 데이터의 자연적 단절점과 놀라울 정도로 일치한다. 트리 기반 모델이라면 구간 분할 대신 $\log(\text{배아수}+1)$ 연속 변수로 사용해도 동일한 비선형을 자동 학습한다.

Part 03

미세주입 피처의 구조적 특수성

#40(미세주입된 난자 수)과 #41(미세주입에서 생성된 배아 수)은 총 생성 배아 수와 겉보기만 비슷하다. 0의 의미부터 다르다.

구조적 차이 - 0의 의미가 완전히 다름

특성	총 생성 배아 수	미세주입 난자 수 (#40)
0인 비율	~1%	51.1%
0의 의미	드문 실패	ICSI 자체를 안 한 케이스

특성	총 생성 배아 수	미세주입 난자 수 (#40)
시술 유형과 관계	무관	#40=0일 때 IVF 71% / #40>0일 때 ICSI 94%

즉 #40의 0은 "실패"가 아니라 **구조적 0(structural zero)**이다. 이걸 "배아 0~6개"와 같은 방식으로 묶으면 안 된다.

진짜 가치는 "비율"에 있다

ICSI 수정률 = #41 / #40 (ICSI 시행한 12.2만 건 대상)을 만들면 다음과 같은 깨끗한 역U자 패턴이 나타난다.

수정률 구간	건수	비율	임신 성공률
0% (전체 실패)	4,103	3.4%	0.54%
1~30%	5,798	4.7%	16.73%
31~50%	21,303	17.4%	21.86%
51~70%	28,594	23.4%	29.15%
71~90%	38,796	31.7%	32.93%
91~100%	23,795	19.4%	27.93%

권장 파생변수

변수명	정의	역할
is_ICSI	#40 > 0	시술 유형 플래그
ICSI_수정률	#41 / (#40+1)	가장 강력한 예후 지표
ICSI_실패수	#40 - #41	배아화 실패 수 (정자·난자 질 신호)
ICSI_비중	#40 / 총 생성 배아 수	ICSI 의존도

Part 04

남성요인 × ICSI 상호작용

ICSI는 남성요인이 있을 때만 효과가 있는 치료다. 단일 변수로는 절대 포착할 수 없고, 교차시키는 순간 강력한 신호가 된다.

2×2 매트릭스: 임신 성공률

ICSI 미시행

ICSI 시행

남성요인
없음

25.39%

n = 97,034 · 38.8%

기준군

24.38%

n = 54,910 · 22.0%

과사용 의심

남성요인
있음

24.07%

n = 30,635 · 12.3%

부적합 매칭

29.66%

n = 67,481 · 27.0%

적합 매칭 🏆

상호작용 효과

남성요인 있음 → ICSI 시행 시 성공률 +5.59%p (24.07% → 29.66%)

남성요인 없음 → ICSI 시행 시 성공률 -1.01%p (25.39% → 24.38%)


ICSI는 "남성요인이 있을 때만" 효과가 있는 치료다. 단일 변수로는 포착 불가능한 신호가 교차 변수에서만 드러난다.

수정률별로 봐도 같은 패턴

ICSI 수정률 구간 × 남성요인별 임신 성공률

모든 수정률 구간에서 남성요인 있는 쪽이 4~6%p 더 높음

남성요인 없음 남성요인 있음



권장 파생변수

변수명	정의	의미
기술적합성	4범주: 적합ICSI / 과사용 / 부적합 / 해당없음	가장 해석 가능하고 강력한 단일 피쳐
ICSI_적합	남성요인 AND ICSI시행	성공률 최강 예측자 (29.66%)
ICSI_수정률 × 남성요인	교호항 (곱)	선형 모델용 상호작용


Part 05

미세주입 남자 수의 최적 구간

많을수록 좋다는 직관은 틀렸다. 10~19개에서 최고점을 찍고 이후 떨어지는 역U자 관계가 뚜렷하다.

미세주입 남자 수별 임신 성공률 곡선

전체 성공률은 10~19개에서 피크 · 이식 후 성공률은 단조증가 · 수정률은 일정



전체 성공률은 역U자, 이식 후 성공률은 단조증가

구간	건수	전체 성공률	이식만 성공률	freeze-all 비율
1~3개 (저반응)	18,743	12.15%	16.36%	25.77%
4~5개	20,241	23.39%	26.09%	10.34%
6~9개	39,791	29.78%	32.48%	8.39%
10~14개 ★	28,391	34.33%	37.74%	9.08%

구간	건수	전체 성공률	이식만 성공률	freeze-all 비율
15~19개 ★	10,532	33.99%	40.21%	15.51%
20~24개	3,301	28.93%	41.68%	30.66%
25개 이상	1,392	18.75%	39.91%	53.02%

중요한 포인트

25개 이상인 경우 절반 이상(53%)이 당기 이식을 안 한다 — OHSS 위험 때문에 전부 동결. 20개 초과에서의 성공률 하락은 배아 품질 문제가 아니라 의학적 회피 전략이다. 다음 주기 이식에서 회수될 가능성이 높다.

나이별 최적점

연령	최적 구간	해석
만 18-34세	10~14개	난자 품질 우수 → 적당한 수로 충분
만 35-39세	15~19개	품질 저하 보완 위해 더 많이 필요
만 40세 이상	15~19개	확률 게임이 유리

임상 문헌과의 일치

기준	정의	본 데이터 확인
Bologna 기준 (저반응)	≤ 3개 난자	✅ 1-3개 성공률 12% (다른 구간의 1/3)
"Optimal yield" (Sunkara 등)	10~15개	✅ 데이터와 완벽히 일치
OHSS 위험 경계	15~18개 이상	✅ 15+ 부터 freeze-all 급증
Excessive response	20개 이상	✅ 성공률 급락 + freeze-all 30%+

Part 06

파이프라인 단계 매핑

미세주입된 난자 수는 IVF 7단계 파이프라인의 ② 성숙 난자 단계에 해당한다. 데이터 평균이 임상 교과서의 예시와 거의 정확히 맞아떨어진다.

01 채취한 난자

약 10개 · 배란 유도로 여러 개 채취

수집된 신선 난자 수
데이터 평균 10.43개

02

성숙 난자 (ICSI 주입)
약 8개 · 미성숙 제외 → ICSI 대상으로 선별

미세주입된 난자 수 (#40)
데이터 평균 8.52개 · 성숙률 ~82%

03

수정된 난자
약 6개 · 수정 실패 제외

데이터에 별도 컬럼 없음
④ 단계와 합쳐서 집계

04

생성된 배아
약 5개 · 발달 멈춤 제외

미세주입에서 생성된 배아 수 (#41)
데이터 평균 5.81개 · ② 대비 ~68%

05

이식 가능한 배아
약 3개 · 품질 기준 미달 제외

데이터에 별도 컬럼 없음
⑥/⑦로 분배

06

이식된 배아
1~2개 · 한 번에 소수만

이식된 배아 수
데이터 평균 1.42개

07

저장된 배아
1~2개 · 남은 것 동결 보관

저장된 배아 수
데이터 평균 1.29개

단계별 전환율 — 새 파생변수 후보

전환율	정의	의미	평균
성숙률	#40 / 수집 신선 남자	난소 자극 반응의 질	~82%
ICSI 수정·발달률	#41 / #40	ICSI 효율성	~68%
이식 가능률	(이식+저장) / #41	배아 품질 통과율	~47%
이식 채택률	이식 / (이식+저장)	당기 이식 vs 동결 전략	~52%


Part 07

파생변수 실험 — 원본을 빼도 되는가

"남성요인, #40, #41을 하나의 파생변수로 압축하고 원본은 뺀다"는 전략이 가능한지를 실험으로 검증했다. 결과는 명확하다 — 원본은 그대로 유지해야 한다.

피쳐 세트별 AUC 성능 비교

70% 학습 / 30% 테스트 · Logistic Regression & Gradient Boosting



실험 결과

모델	피쳐 구성	LR AUC	GBM AUC	변화 (LR)
A	원본 3변수 (기준)	0.55645	0.58600	—
B	파생만 (적합성+수정률)	0.55340	0.57247	-0.30%p
C	파생만 (적합성 1개)	0.52085	0.52943	-3.56%p ▲
D	원본+파생 전체 🏆	0.57199	0.58613	+1.55%p

모델	피쳐 구성	LR AUC	GBM AUC	변화 (LR)
E	파생+F40 (크기 보존)	0.56145	0.58594	+0.50%p

왜 그런가 — 같은 범주 안에서도 F40이 성공률을 좌우

"시술적합성 = 3 (남성요인O + ICSI 적합)" 범주 안에서조차, F40 값이 달라지면 성공률이 이렇게 변한다.

F40 구간	적합성=3 (남성요인O)	적합성=2 (남성요인X)
1~3개	14.35%	10.38%
4~9개	29.14%	25.85%
10~14개	36.25%	31.35%
15~19개	35.62%	31.32%
20개 이상	27.02%	24.22%

정보 손실의 정체

같은 "적합" 범주 안에서도 성공률이 14% → 36% → 27%로 22%p 변동한다. 시술적합성 하나로는 절대 잡지 못하는 신호다. 파생변수는 본질적으로 차원 압축이며, 압축 과정에서 "절대 크기(volume)" 정보가 날아간다.

모델 유형별 전략

시나리오	전략
해석 가능한 최대 성능 (선형 모델)	✔ 원본 3변수 + 파생 2개 (Model D) — 절대 원본 빼지 말 것
최대 성능 추구 (XGBoost/LightGBM)	✔ 원본 3변수만 써도 충분 (D ≈ A, 트리가 상호작용 자동 학습)
피쳐 수 최소화	🟡 Model E (파생 + F40) — 크기 정보는 보존
원본 빼고 파생만	✖ 추천 불가 — 최소 0.3%p, 최대 5.7%p 손실



파생변수는 원본의 대체재가 아니라 보완재다. 파생변수는 "상호작용" 정보를 선형 모델에 명시적으로 주입하는 역할을 할 뿐, 원본이 담고 있는 "크기(scale)" 정보는 복원하지 못한다. 원본은 그대로 유지하고, 파생변수를 추가하는 것이 Dominant Strategy.

도메인 지식 토대 — IVF 7단계

데이터의 수많은 컬럼이 어느 시점의 기록인지 이해하려면, 먼저 IVF 시술이 2~3주에 걸쳐 어떤 단계를 거치는지 알아야 한다. 이 지도가 이후 모든 해석의 기초가 된다.

시술 타임라인

STEP 01

배란 유도

호르몬제로 여러 난포를 동시 자극. 자연 상태 1~2개 → 시술 10개 이상

배란 유도 유형

STEP 02

난자 채취

난포에서 난자를 바늘로 흡입 (수면마취)

수집된 신선 난자 수 (#48)

난자 채취 경과일

STEP 03

정자 준비

남편 또는 기증자의 정자를 받아 활동성 좋은 것만 선별

정자 출처

STEP 04

수정

IVF = 살레에 섞어 자연수정 / ICSI = 정자 1개를 난자에 직접 주입

혼합된 난자 수 (#50)

미세주입된 난자 수 (#40)

STEP 05

배양

3일(분할기) 또는 5~6일(배반포)간 인큐베이터에서 키움

총 생성 배아 수 (#39)

배아 발달 단계

STEP 06

이식 또는 동결

질 좋은 배아 1~3개 이식. 나머지는 동결 보관

이식된 배아 수 (#42)

저장된 배아 수 (#44)

STEP 07

착상 및 확인

2주 후 hCG 혈액검사로 임신 여부 확인

임신 성공 여부 ← TARGET

핵심 용어 사전

배아 (Embryo) 정자 + 난자가 만나 형성된 초기 생명 (수정 후 8주까지)
배반포 (Blastocyst) 배양 5~6일차 배아. 이식 성공률이 가장 높은 단계
분할기 (Cleavage) 배양 2~3일차 배아. 세포 4~8개 단계
착상 (Implantation) 배아가 자궁벽에 붙는 과정. 이게 되어야 임신
신선 주기 (Fresh) 채취 → 수정 → 바로 이식 (동결 없음)
동결 주기 (FET) 이전에 동결한 배아를 녹여서 이식. 신선 주기와 다른 프로토콜
ICSI (미세주입) 정자 1개를 난자에 직접 주사. 주로 남성 요인 난임
PGT-A / PGT-M 착상 전 유전 선별검사(A=염색체)/진단(M=특정 질환)

시술 유형의 3가지 종류

시술명	방법	역할	성공률
IUI (인공수정)	정자를 자궁에 직접 주입	나팔관까지만 도와줌	10~15%
IVF (체외수정)	난자+정자를 실험실에서 만남	수정 단계를 대신	25~30%
ICSI (미세주입술)	정자를 난자에 직접 주입	수정을 강제로 시킴	27~30%

연령별 성공률 — 가장 강한 단일 예측 변수

연령대	난자 질	IVF 성공률	특징
20대~34세	최상	35~45%	표준 프로토콜, 양질 배아
35~37세	양호	30~35%	이식 개수 증가 고려
38~40세	감소	20~25%	PGT-A 권장 시작
41~42세	빠른 감소	10~15%	단일 시도로 어려움
43세 이상	심각한 감소	5% 이하	기증 난자 고려

Part 09

피처 확장 가이드 (29~52번)

24개 피처를 세 그룹으로 나누어 의학적 의미와 파생변수 설계 원칙을 정리한다. 각 그룹마다 반드시 만들어야 할 "킬러 피처"가 있다.

Group A. 시술·임신·출산 횟수 (#29~38) — 10개 피처

10개 컬럼이 3×3 매트릭스 구조로 설계되어 있다. 모든 값이 '0회' ~ '6회 이상' 문자열이므로 반드시 정수 변환 + is_censored 플래그를 동반해야 한다.

	시술 횟수	임신 횟수	출산 횟수
전체	#29 총 시술	#32 총 임신	#35 총 출산
IVF	#30 IVF 시술	#33 IVF 임신	#36 IVF 출산
DI	#31 DI 시술	#34 DI 임신	#37 DI 출산

킬러 피처

ever_delivered = (총 출산 > 0) — 이 데이터셋에서 가장 강력한 단일 예측 변수. 과거에 출산했다는 건 "임신과 출산이 가능한 몸"의 증거이다. Templeton 1996, Barnett-Itzhaki 2020 등 수십 년 논문이 검증.

핵심 파생변수

- ever_delivered = 총 출산 > 0 (최강 긍정)
- repeated_3plus = 총 시술 ≥ 3 (강한 부정)
- is_first_attempt = 총 시술 == 0
- prev_birth_rate = 총 출산 / (총 임신 + 1)
- 유산_횟수 = 총 임신 - 총 출산 (반복 유산 시사)
- long_infertility = 임신 경과 연수 ≥ 7 (Templeton 1996)

Group B. 배아 생성과 활용 (#39~46) — 8개 피처

파이프라인 ④~⑦ 단계(배아 생성 → 이식/저장)를 추적한다. 각 단계의 **전환율**이 환자 예후를 개수보다 더 잘 반영한다. **논리 제약**이 많으니 반드시 검증.

논리 제약 (반드시 검증)

- #41 (미세주입 배아) ≤ #40 (미세주입 난자)
- #42 + #44 (이식 + 저장) ≤ #39 (총 생성 배아)
- #43 (미세주입 배아 이식) ≤ #42
- #45 (미세주입 배아 저장) ≤ #44

파이프라인 전환율 (핵심 4개)

전환율	정의	의미
배아_생성률	#39 / (#48 + 1)	채취 난자 대비 배아 수율 (난자·정자 종합 질)
ICSI_수정률	#41 / (#40 + 1)	ICSI 효율 (역U자 패턴, 71~90%에서 피크)
이식_비율	#42 / (#39 + 1)	생성 배아 대비 이식 채택
저장_비율	#44 / (#39 + 1)	여유 배아 비율 (양질 사이클 신호)

IS_FET 플래그 - TOP 5 중요 피처

is_FET = (#46 해동된 배아 수 > 0) — 동결 주기 vs 신선 주기를 가르는 이 플래그는 거의 모든 다른 컬럼의 해석에 영향을 준다. 성공률, 배란 유도 여부, 배아 특성이 FET/Fresh에 따라 다르게 작동. 모델을 Fresh/FET로 나눠 앙상블하는 전략도 고려 가능.

Group C. 난자·정자 관련 (#47~52) — 6개 피처

배아 이전 단계(난자·정자)에 대한 정보. 이 숫자들은 배아 파이프라인의 "**분모**" 역할을 하며, 기증 여부 같은 특수 케이스를 구분하는 열쇠이기도 하다.

논리 제약

- #49 (저장된 신선 난자) ≤ #48 (수집된 신선 난자)
- #50 (혼합) + #40 (미세주입) ≈ #48 - #49
- #51 (파트너 정자 혼합) + #52 (기증자 정자 혼합) ≈ #50

핵심 파생변수

파생변수	정의	의미
난소_반응_구간	#48 기준 저반응/정상/과반응 범주화	배란 유도 성과 (Part 05 결과 반영)
is_동결난자	#47 > 0	동결 난자 사용 (희귀 특수케이스)
is_Split	#50 > 0 AND #40 > 0	혼합-ICSI 병행 (불확실성 케이스)
is_기증정자	#52 > 0	기증 정자 사용 (심한 남성 요인)
파트너정자_비율	#51 / (#50 + 1)	본인 부부 vs 기증 비중

Part 10

데이터 품질 · 논리 제약 검증

실제 모델 학습 전에 반드시 통과해야 하는 데이터 품질 게이트. NaN과 censored 값은 "버리는 것"이 아니라 "피쳐로 바꾸는 것"이다.

NaN 처리 원칙 — 결측에는 이유가 있다

상황	원본 값 예시	처리 방법
숫자의 상한 (censoring)	'6회 이상'	<code>6 + is_censored</code> 플래그
카테고리 희귀값	'생식선 자극 호르몬' 1건	'알 수 없음'에 통합
알 수 없음	'Unknown', '알 수 없음'	별도 카테고리 유지 (제거 금지)
구조적 NaN	DI 시술의 배아 컬럼	명시적 '해당없음' 값 (imputation 금지)
주기 구조 NaN	FET의 배란유도 컬럼	<code>is_FET</code> 플래그로 전환

핵심 원칙

- 결측에는 항상 이유가 있다. 그 이유를 **피쳐로 만들어라**.
- '배란 유도 유형' NaN → FET 사이클 → `is_FET` 으로 연결
 - '배아 관련' NaN → DI 시술 → `is_DI` 로 연결
 - '유전 검사' NaN → 시행 안 함 → 결측이 정상

결측치 제거 기준

- 결측률 84% 이상: **대체해도 신뢰 불가** → 제거 검토
- 분산 = 0: **전체가 동일값**, 학습 불가 → 제거
- 분산 < 0.0099: 한쪽 값 극히 적어 패턴 학습 불가

- 타겟과 상관계수 = 0: 예측에 기여 없음
- 단, **난자 기증자 나이 '알 수 없음'** 같은 경우는 "기증 여부" 파생변수로 전환해서 활용

전처리 체크리스트

Phase A. 데이터 이해 (시작 전 필수)

- 전체 row·column 수, dtype 확인
- 결측치 비율 heatmap (컬럼별)
- 타겟 분포 (클래스 불균형) · IVF vs DI 비율 · 나이 분포
- 중복 row 체크

Phase B. 기본 전처리

- 문자열 숫자 변환: '0회'~'6회 이상' → 정수 + `is_censored`
- boolean 컬럼 (True/False → 1/0) 통일
- 시술유형 희귀값 통합 또는 피처 분해 (주기법/배반포여부/반복시도/조합시술)
- 배아 생성 주요 이유 → 5개 multi-hot flag 분해
- 경과일 컬럼 이상치 (음수, 극단값) 체크
- 논리 제약 위반 행 탐지 및 리포트

× 절대 피해야 할 실수들

× **Target Leakage**: 이번 시술 이후 정보(hCG 수치, 이식 후 호르몬 등)를 피처로 쓰면 안 됨

× **censored 무시**: '6회 이상'을 6으로만 변환하면 환자 A(6회)와 B(12회)가 같아짐 — 반드시 `is_censored` 동반

× **구조적 NaN에 평균 imputation**: DI 환자의 배아 컬럼을 0이나 평균으로 채우면 의미 왜곡

× **희귀 카테고리 one-hot 그대로**: 10건 미만은 target encoding 또는 통합

× **비율 계산 시 0 나눗셈**: 분모에 +1 스무딩 필수 (특히 임신 횟수 0인 환자)

× **파생변수만 쓰고 원본 빼기**: Part 07에서 -5.7%p 손실 확인

× **파생변수 100개+ 한꺼번에**: 의미 있는 피처가 묻힘 — RFE/SHAP로 50~100개로 정리

Part 11 ★

다음 단계 실행 로드맵

지금까지 분석한 모든 내용을 실제 모델링으로 옮기기 위한 단계별 계획. 각 Phase는 독립적으로 검증 가능하도록 설계했다.

01

기초 전처리 & 데이터 품질 검증

1~2일

목표: 모델이 학습할 수 있는 상태로 데이터 정비, 논리 제약 위반 탐지

TASKS

- ☐ '0회'~'6회 이상' → 정수 변환, `is_censored` 플래그 10개 생성 (#29~38)
- ☐ 불임 원인 boolean 7개 컬럼 (#11~17, #18~27) 타입 통일
- ☐ 시술유형 `특정시술유형` 24개 카테고리 분포 확인
- ☐ 배아 생성 주요 이유 (#28) → 5개 flag 분해 (`is_현재시술용` , `is_기증용` , `is_배아저장용` , `is_난자저장용` , `is_연구용`)
- ☐ 경과일 컬럼 이상치 (음수/극단값) 탐지
- ☐ 논리 제약 위반 행 카운트: `#41 ≤ #40` , `#42+#44 ≤ #39` , `#43 ≤ #42` , `#45 ≤ #44` , `#49 ≤ #48`

산출물 타입 변환 완료 DataFrame · 논리 제약 리포트 · 결측 패턴 요약 · EDA 노트북

02

도메인 & 분석 기반 핵심 파생변수 20개

2~3일

목표: 문헌 검증된 강력 피처 + 본 분석에서 찾은 신호를 모두 파생변수로 구현

A. 문헌 검증 피처 (6개)

- ☐ `ever_delivered` = 총 출산 > 0 ★ 최강 긍정
- ☐ `repeated_3plus` = 총 시술 ≥ 3 (강한 부정)
- ☐ `is_first_attempt` = 총 시술 == 0
- ☐ `prev_birth_rate` = 총 출산 / (총 임신 + 1)
- ☐ 유산_횟수 = 총 임신 - 총 출산
- ☐ `is_FET` = 해동 배아 수 > 0 ★ Top 5 예측자

B. 본 분석 기반 피처 (6개) - PART 01~07의 결론

- ☐ 시술적합성 4범주: 남성요인 × ICSI 매칭 (Part 04, 성공률 22 → 30%p 구분)
- ☐ ICSI_수정률 = `#41 / (#40 + 1)` (Part 03, 역U자)
- ☐ 배아수_그룹 4범주: 0-6 / 7-14 / 15-20 / 21+ (Part 02, 임상 기준 일치)
- ☐ ICSI_난자_구간 4범주: 1-3 / 4-9 / 10-19 / 20+ (Part 05, sweet spot 10-19)
- ☐ `eset_blast` = 단일이식 AND 배반포 (Kawwass 2013, OR 1.17 × 2.32)
- ☐ 이식_취소 = `#42 == 0` (freeze-all 신호)

C. 파이프라인 전환율 4개 (PART 06)

- ☐ 성숙률 = `#40 / (#48 + 1)` — 약 82%

- ☐ ICSI_수정발달률 = #41 / (#40 + 1) — 약 68%
- ☐ 이식가능률 = (#42 + #44) / (#39 + 1) — 약 47%
- ☐ 이식채택률 = #42 / (#42 + #44 + 1) — 약 52%

D. 나이 & 상호작용 4개

- ☐ 나이_구간 5범주 (비선형 효과가 크므로 범주형 유지)
- ☐ 나이_X_시술횟수 상호작용 — 고령 + 반복 = 최악 조합
- ☐ 나이_X_배아수 — 같은 수라도 나이별 해석 다름
- ☐ 원인_시술_매칭점수 — 남성요인 ↔ ICSI, 배란장애 ↔ 배란유도 등

산출물 원본 + 파생변수 20개 = 총 82개 피처 DataFrame · 각 피처의 분포 및 타겟 상관 요약

03

A/B 실험 & 피처 선택

2일

목표: 각 파생변수의 실제 기여도를 CV로 검증. 추가하는 피처만 살리고 노이즈 제거

5-FOLD CV 실험 설계 (LIGHTGBM BASELINE)

- ☐ 실험 A: 원본 피처만 (baseline AUC 측정)
- ☐ 실험 B: 원본 + 문헌 검증 피처 6개 (그룹 A 추가)
- ☐ 실험 C: 실험 B + 분석 기반 피처 6개 (그룹 B 추가)
- ☐ 실험 D: 실험 C + 전환율 4개 (그룹 C 추가)
- ☐ 실험 E: 실험 D + 상호작용 4개 (그룹 D 추가)
- ☐ 실험 F: 실험 E에서 SHAP 기여도 하위 10% 제거 (최종)

검증 체크

- ☐ ΔAUC 측정 — 0.001 미만 개선은 과감히 제거
- ☐ SHAP 값 상위 20개 확인 — 예상과 일치하는지
- ☐ Train/Test 분포 일치 확인 (covariate shift)
- ☐ Target Leakage 재검토 (너무 높은 상관은 의심)

산출물 실험별 AUC 비교표 · SHAP summary plot · 최종 피처 리스트 (50~80개)

04

고도화 (시간 허락시)

3~4일

목표: 상위권 성능을 위한 고급 기법 적용

특정시술유형 피쳐 분해 (전략 3)

- ☐ 주기법 = extract(IVF / ICSI / IUI)
- ☐ is_배반포 = contains('BLASTOCYST') — 긍정 신호
- ☐ is_반복시도 = contains(':') — 부정 신호 (성공률 1%)
- ☐ is_조합시술 = contains('/')

고급 인코딩

- ☐ 종합 프로파일 (원인 조합) Target Encoding
- ☐ 희귀 카테고리 mean encoding with smoothing
- ☐ 나이 × 원인 × 시술 3중 상호작용 생성

모델 고도화

- ☐ Fresh vs FET 분리 모델 후 앙상블
- ☐ LightGBM + CatBoost + XGBoost 스택킹
- ☐ Optuna로 하이퍼파라미터 튜닝
- ☐ Stratified K-Fold (연령대 × 타겟)

산출물 최종 앙상블 모델 · 재현 가능한 파이프라인 · 제출 파일

05

발표 스토리텔링

1~2일

목표: 모델 성능만큼 "왜 이 피쳐인가"의 서사로 차별화

5가지 스토리 축

- ☐ 배아 파이프라인 추적: "단순 개수가 아닌 감소 패턴"에서 예후 읽기 — 전환율 5개 피쳐 스토리
- ☐ 원인-시술 매칭 분석: 남성요인 + ICSI = +5.6%p (Part 04의 2×2 매트릭스 활용)
- ☐ 문헌 기반 피쳐: Templeton 1996, Kawwass 2013, Barnett-Itzhaki 2020 인용 + ever_delivered 효과 데모
- ☐ 숨은 구조 신호: "NaN에는 이유가 있다" — is_FET / is_DI / 구조적 결측 전환
- ☐ 겉보기 vs 실제: "배아 1개 이식"의 두 얼굴 — eSET(40%) vs 중간 탈락(12%)

시각 자료

- ☐ SHAP Summary Plot — 상위 20개 피쳐 영향도
- ☐ 2×2 매트릭스 (남성요인 × ICSI) — 본 리포트 Part 04 재활용
- ☐ 배아 수 역U자 곡선 — 본 리포트 Part 05 재활용
- ☐ IVF 7단계 파이프라인 — 본 리포트 Part 06-08 재활용

산출물 발표 슬라이드 · 스토리 대본 · 핵심 시각 자료 5종

우선순위 요약

Phase	핵심 작업	예상 효과	리스크
01	타입 변환 · 논리 검증 · <code>is_censored</code>	모델 학습 가능 상태 확보	❌ 생략하면 이후 모든 단계 실패
02	파생변수 20개 생성	+3~5%p AUC 상승 기대	타입 오류 · 0 나눗셈
03	A/B 실험 · SHAP 검증	신호/노이즈 분리	실험 계획 없으면 혼란
04	양상블 · 튜닝	+1~2%p 추가	시간 소모 · 과적합
05	스토리텔링	발표 점수 차별화	성능만 강조 시 매력 부족

추천 진행 순서

Phase 01 → 02 → 03은 필수 + 순차적. Phase 03에서 AUC 상승이 유의미하게 확보되면 곧바로 Phase 05 스토리 뼈대를 병행 작성하는 것을 권장한다. Phase 04는 시간 여유가 있을 때만 추가. "완벽한 Phase 04보다 잘 정리된 Phase 03 + 05"가 해커톤에서는 대부분 상위권에 유리하다.

최종 성공 지표

BASELINE → FINAL

+3~6 %p

AUC 기대 상승폭
(Phase 02-03 완료 시)

최종 피쳐 수

50 ~80개

원본 62 + 파생 20
- SHAP 하위 제거

검증 방식

5 -fold CV

Stratified by target
재현성 중시



데이터가 말하는 소리를 들어주세요. '왜?'를 던질 때마다 상위권에 가까워집니다.
모든 피처에는 배경이 있고, 모든 결측에는 이유가 있고, 모든 극단값에는 사연이 있습니다.

— End of report —

IVF Data Analytics · Feature Engineering & Execution Roadmap · 2026.04 · v2

Dataset: train.csv (250,060 records) · Target: 임신 성공 여부 (positive rate 26.16%)

Parts 01~07: Exploratory analysis · Parts 08~10: Domain foundation · Part 11: Action plan